

THUYẾT MINH NHIỆM VỤ THÀNH VIÊN 2 (TV2)

Dự án: Phân loại bạch cầu cấp ALL/AML từ dữ liệu biểu hiện gen (Golub et al., 1999)

Phân công: Thành viên 2 (TV2)

Phạm vi: Công việc 1.1 (GĐ1) và 2.4 (GĐ2)

Thời gian: Tuần 1 - Tuần 7

TỔNG QUAN VAI TRÒ: Theo Bảng 5.2 của kế hoạch, **TV2** là người dựng **hạ tầng dữ liệu** ở Giai đoạn 1 (công việc 1.1: nạp, ghép dữ liệu và kiểm tra chất lượng), rồi dựng tiếp **hạ tầng đánh giá dùng chung** ở Giai đoạn 2 (công việc 2.4: khung đánh giá và thí nghiệm **selection bias**, giả thuyết H3). Đầu ra của 1.1 là đầu vào của mọi công việc khác; hàm đánh giá của 2.4 được TV1 và TV3 dùng từ tuần 5.

1. GIAI ĐOẠN 1 — CÔNG VIỆC 1.1: NẠP, GHÉP DỮ LIỆU VÀ KIỂM TRA CHẤT LƯỢNG (TUẦN 1-4, DEADLINE 10/10)

Mục tiêu: Đưa bộ dữ liệu Golub từ Kaggle và metadata OpenIntro vào dạng dùng được cho cả nhóm, đáng tin cậy và tái lập được.

Các đầu việc chi tiết:

- **Quản trị dữ liệu thô:** Tải 3 file Kaggle (data_set_ALL_AML_train.csv, data_set_ALL_AML_independent.csv, actual.csv) và golub.csv của OpenIntro vào data/raw/; ghi data/raw/SOURCES.md gồm **link, ngày tải và MD5** từng file để chứng minh dữ liệu gốc không bị thay đổi.
- **Thiết lập hạ tầng dự án:** Dựng repo GitHub, cấu trúc thư mục theo mục 2.2, environment.yml **cố định phiên bản** Python và thư viện (mục 2.7), Makefile (make data, make test...), src/config.py.
- **Module nạp và ghép dữ liệu (src/load.py):** Theo đúng 7 bước mục 2.1.2: ghép theo **mã bệnh nhân (sample_id)**, **không bao giờ theo thứ tự dòng**; đọc OpenIntro chỉ 6 cột mô tả (usecols); left join metadata vào bảng mẫu với validate="one_to_one"; kiểm tra sau ghép (đủ 72 mẫu, không mẫu nào thiếu metadata, class khớp subtype 72/72, tissue.mf khớp tissue + sex). Xuất 4 file tầng standardized (expression, calls, samples, genes) và hàm **load_golub()** cho cả nhóm.
- **Module kiểm tra chất lượng (src/quality.py):** Kiểm tra đủ **4 mức của Bảng 2.9**: Value (NaN, giá trị < 100 và > 16000), Value-set (probe AFFX, nhiều probe cho cùng một gen, metadata ngoài danh mục), Record (mẫu trùng lặp; mẫu bất thường qua tương quan giữa các mẫu và boxplot theo mẫu → **gắn cờ qc_outlier, không xóa**), Relation (nhãn Kaggle khớp subtype OpenIntro, phân bố Bảng 2.4). Ghi tầng cleansed và quality_report.md; có kiểm tra FAIL thì dừng pipeline.
- **Kiểm thử tự động và tài liệu:** tests/test_load.py kiểm tra **toàn bộ Bảng 2.4** (kích thước, class, split × class, split × tissue, nguồn mẫu train/test, subtype, khớp nhãn 72/72); docs/data_dictionary.md; soạn mục 2.1-2.5 và 2.7 của báo cáo cuối kỳ.

Mốc phối hợp (theo kế hoạch):

Mốc	Nội dung	Người nhận / liên quan
T7 10/10	Hạn hoàn thành công việc 1.1	Cả nhóm
CN 11/10	Giao load_golub() bản tạm	TV3 (công việc 1.2)
CN 18/10	Giao samples.parquet chính thức	TV1 (công việc 1.3)
CN 01/11	Trình bày 10 phút, chạy demo nghiệm thu; nộp docs/handover/1.1.md	Trưởng nhóm (TV1)

Sản phẩm bàn giao Giai đoạn 1:

Hạng mục	Tên file / Sản phẩm	Mô tả / Vị trí
Mã nguồn xử lý	src/load.py src/quality.py	Nạp/ghép dữ liệu; kiểm tra chất lượng 4 mức
Mã nguồn kiểm thử	tests/test_load.py	Kiểm tra toàn bộ Bảng 2.4 sau khi ghép
Tầng standardized	data/standardized/*.parquet	expression, calls, samples, genes — cùng cấu trúc, chưa đánh giá chất lượng
Tầng cleansed	data/cleansed/*	Đã kiểm tra chất lượng; giá trị biểu hiện giữ nguyên, samples thêm cột qc_outlier. Tầng sẵn sàng cho phân tích là curated (TV3)
Báo cáo chất lượng	data/cleansed/quality_report.md	Sinh tự động bằng make quality; không đưa lên Git (data/ nằm trong .gitignore)
Tài liệu kỹ thuật	docs/data_dictionary.md docs/decisions.md	Từ điển dữ liệu; nhật ký quyết định
Báo cáo	Mục 2.1-2.5, 2.7	Nguồn dữ liệu, lưu trữ, mô hình dữ liệu, pipeline, chất lượng, quản trị

Demo nghiệm thu (mục 5.2 của kế hoạch; số liệu phải khớp Bảng 2.4):

```
$ make data && pytest tests/test_load.py
>>> from src.load import load_golub
>>> X, samples = load_golub(layer='cleansed')
>>> X.shape, samples.shape
((72, 7129), (72, 7))      # 6 cột mô tả + cột cờ qc_outlier
>>> samples['class'].value_counts()      # ALL 47, AML 25
>>> pd.crosstab(samples['split'], samples['class']) # train 27/11, test 20/14
Trích quality_report.md:
[PASS] 72 mẫu, 7129 probe, không trùng sample_id
[PASS] Nhân Kaggle khớp subtype OpenIntro: 72/72
[INFO] Số giá trị < 100: ... Số giá trị > 16000: ... Probe AFX: ...
[INFO] Mẫu gắn cờ qc_outlier: ... (lý do: ...)
```

2. GIAI ĐOẠN 2 — CÔNG VIỆC 2.4: KHUNG ĐÁNH GIÁ VÀ THÍ NGHIỆM SELECTION BIAS (TUẦN 5-7)

Mục tiêu: Đảm bảo mọi con số hiệu năng là trung thực và chứng minh bằng thực nghiệm tác hại của đánh giá sai (giả thuyết H3).

Các đầu việc chi tiết:

- **Khung đánh giá dùng chung (src/evaluate.py):** Hàm **evaluate(pipeline, X, y, scheme, seeds)** cho 4 sơ đồ của mục 3.5.1: original_split (38/34), loocv (trên 38 mẫu train, chọn gen lại ở mỗi fold, chỉ số tính trên dự đoán gộp), nested_cv (stratified lặp lại, vòng trong chọn k và siêu tham số) và wrong_cv (chọn gen trên toàn bộ dữ liệu rồi mới CV — chỉ để minh họa). Số fold, số lần lặp và seed đọc từ config/experiment_config.yaml của TV1. Kết quả trả về gồm bal_acc_mean, bal_acc_sd, auc_mean, per_fold, config (và predictions để kiểm định, vẽ ROC).
- **Chỉ số và kiểm định thống kê:** Balanced accuracy (chỉ số chính), AUC-ROC, sensitivity và specificity (**AML là lớp dương**); khoảng tin cậy Wilson 95% cho accuracy trên tập test; trung bình $\pm$ độ lệch chuẩn qua các lần lặp CV; kiểm định McNemar cho cặp mô hình trên tập test.
- **Thí nghiệm selection bias (H3):** Bảng 2×2 : nhãn thật / nhãn hoán vị ngẫu nhiên (100 lần) $\times$ CV đúng (chọn gen trong pipeline) / CV sai (chọn gen trước CV). Với nhãn hoán vị, CV đúng phải quanh 0.50; CV sai cao bất thường là bằng chứng H3. Vẽ hình F10 (violin/strip plot, đường tham chiếu 0.5).
- **Đánh giá mô hình cuối:** Vẽ đường cong ROC và ma trận nhầm lẫn cho mô hình cuối được nhóm thống nhất chọn (hình F11).

- **Rà soát rò rỉ dữ liệu:** Review code của TV1, TV3, TV4: mọi bước học từ dữ liệu (lọc gen, chuẩn hóa, chọn gen) phải nằm trong Pipeline và chỉ fit trên phần huấn luyện của từng fold; không bước nào nhìn thấy fold kiểm tra hay tập test độc lập.

Mốc phối hợp (theo kế hoạch):

Mốc	Nội dung	Người nhận / liên quan
Đầu tuần 5	Giao evaluate.py bản 1 (hàm evaluate dùng chung)	TV1 (2.1), TV3 (2.3)
Tuần 5	Nhận config/experiment_config.yaml; giao định dạng file số liệu F10/F11	TV1 / TV6
Tuần 5-7	Review rò rỉ dữ liệu khi có code	TV1, TV3, TV4
Tuần 6-7	Giao số liệu thật cho F10, F11; viết mục 3.5	TV6, trưởng nhóm

Sản phẩm bàn giao Giai đoạn 2:

Hạng mục	Tên file / Sản phẩm	Mô tả / Vị trí
Khung đánh giá	src/evaluate.py	evaluate(), wilson_ci(), mcnemar_test(), selection_bias_experiment()
Mã nguồn kiểm thử	tests/test_evaluate.py	Kiểm tra 4 sơ đồ, Wilson, McNemar trên dữ liệu tổng hợp
Notebook thí nghiệm	notebooks/08_evaluation.ipynb	Thí nghiệm selection bias và kiểm định McNemar
Hình F10	results/figures/report/ F10_selection_bias_report.png results/figures/slides/ F10_selection_bias_slide.png	Phân phối balanced accuracy: CV đúng vs CV sai, nhãn thật vs hoán vị
Hình F11	results/figures/report/ F11_final_model_roc_cm_report.png results/figures/slides/ F11_final_model_roc_cm_slide.png	ROC và ma trận nhầm lẫn của mô hình cuối
Bảng tổng hợp chỉ số	results/metrics/summary_*.csv	Đưa thẳng vào báo cáo (Bảng 2.6)
Báo cáo	Mục 3.5	Đánh giá mô hình và thí nghiệm selection bias

Demo nghiệm thu (mục 5.3 của kế hoạch):

```
>>> from src.evaluate import evaluate
>>> res = evaluate(pipe, X, y, scheme='nested_cv', seeds=range(10))
>>> res.keys()
dict_keys(['bal_acc_mean', 'bal_acc_sd', 'auc_mean', 'per_fold', 'config', 'predictions'])
```

Nhãn	Cách CV	Balanced accuracy (TB ± SD)	Kỳ vọng
Thật	Đúng	... ± ...	cao
Thật	Sai	... ± ...	cao, có thể cao hơn CV đúng
Hoán vị	Đúng	... ± ...	xấp xỉ 0.50
Hoán vị	Sai	... ± ...	cao bất thường (bằng chứng H3)

3. BẢNG TỔNG HỢP TOÀN BỘ ĐẦU VIỆC CỦA TV2

Giai đoạn	Nhiệm vụ chính	Sản phẩm cụ thể	Mục đích & ý nghĩa
Giai đoạn 1 (Tuần 1-4)	1.1. Nạp, ghép dữ liệu và kiểm tra chất lượng	• src/load.py, src/quality.py • tests/test_load.py • data/standardized/, data/cleansed/ • docs/data_dictionary.md • Báo cáo mục 2.1-2.5, 2.7	Dữ liệu đáng tin cậy, truy vết được về file gốc, tái lập bằng một lệnh cho cả nhóm.
Giai đoạn 2 (Tuần 5-7)	2.4. Khung đánh giá và thí nghiệm selection bias	• src/evaluate.py • notebooks/08_evaluation.ipynb • Hình F10, F11 • Bảng tổng hợp chỉ số • Báo cáo mục 3.5	Mọi con số hiệu năng trung thực; chứng minh H3; rà soát chống rò rỉ dữ liệu.