

THUYẾT MINH NHIỆM VỤ THÀNH VIÊN 2 (TV2)

Dự án: Phân loại bạch cầu cấp ALL/AML từ dữ liệu biểu hiện gen (Golub et al., 1999)

Phân công: Thành viên 2 (TV2)

Phạm vi: Giai đoạn 1 & Giai đoạn 2

Thời gian: Tuần 1 – Tuần 7

TỔNG QUAN VAI TRÒ: Trong dự án phân loại bệnh bạch cầu cấp ALL/AML từ dữ liệu biểu hiện gen, **Thành viên 2 (TV2)** đóng vai trò là **người xây dựng hạ tầng dữ liệu ở Giai đoạn 1** (đưa dữ liệu thô về định dạng chuẩn hóa và kiểm tra chất lượng nghiêm ngặt), sau đó tiếp tục **xây dựng hạ tầng đánh giá mô hình tập trung và thực hiện thí nghiệm chứng minh hiện tượng thiên lệch chọn lọc (Selection Bias) ở Giai đoạn 2**.

1. GIAI ĐOẠN 1: NẠP, GHÉP DỮ LIỆU VÀ KIỂM TRA CHẤT LƯỢNG (TUẦN 1-4, DEADLINE: 10/10)

Mục tiêu giai đoạn: Đưa toàn bộ dữ liệu thô từ Kaggle và metadata từ OpenIntro về định dạng chuẩn hóa, đáng tin cậy, có khả năng truy xuất nguồn gốc và tái lập cao cho toàn bộ các thành viên trong nhóm sử dụng.

Các đầu việc chi tiết:

- Quản trị dữ liệu thô:** Tải và quản lý 3 file dữ liệu Kaggle (`data_set_ALL_AML_train.csv`, `data_set_ALL_AML_independent.csv`, `actual.csv`) và file `golub.csv` của OpenIntro vào thư mục `data/raw/`, đồng thời tạo file `SOURCES.md` lưu mã băm MD5 để đảm bảo tính nguyên vẹn tuyệt đối của dữ liệu.
- Thiết lập hạ tầng dự án:** Khởi tạo kho mã nguồn GitHub, tạo cấu trúc thư mục tiêu chuẩn, thiết lập các file môi trường và cấu hình hệ thống bao gồm `environment.yml`, `Makefile`, và `src/config.py`.
- Xây dựng module nạp và ghép dữ liệu (`src/load.py`):** Lập trình quy trình ghép dữ liệu biểu hiện gen với metadata theo mã bệnh nhân (`sample_id`), kiểm tra quan hệ 1-1. Xuất kết quả ra các file định dạng Parquet tại tầng `standardized/` (gồm `expression.parquet`, `calls.parquet`, `samples.parquet`, `genes.parquet`).
- Xây dựng module kiểm tra chất lượng (`src/quality.py`):** Lập trình kiểm tra chất lượng dữ liệu ở 4 mức độ (Value, Value-set, Record, Relation), tạo dữ liệu tầng `cleansed/` và xuất báo cáo tự động `quality_report.md`.
- Kiểm thử tự động & Tài liệu hóa:** Viết file kiểm thử `tests/test_load.py` để kiểm định tính nhất quán của dữ liệu sau ghép (khớp kích thước, tỷ lệ lớp, nguồn mẫu); lập file `data_dictionary.md` và soạn thảo nội dung các mục 2.1-2.5, 2.7 trong báo cáo cuối kỳ.

Sản phẩm bàn giao Giai đoạn 1:

Hạng mục	Tên file / Sản phẩm	Mô tả / Vị trí
Mã nguồn xử lý	src/load.py src/quality.py	Module nạp/ghép dữ liệu & module kiểm tra chất lượng 4 mức
Mã nguồn kiểm thử	tests/test_load.py	Kiểm thử tự động tính nhất quán sau khi ghép dữ liệu
Dữ liệu tăng chuẩn hóa	data/standardized/*.parquet	Bộ file Parquet chuẩn hóa (expression, calls, samples, genes)
Dữ liệu tăng làm sạch	data/cleansed/*	Dữ liệu đã qua làm sạch và sẵn sàng cho trích xuất đặc trưng
Tài liệu kỹ thuật	docs/data_dictionary.md quality_report.md	Từ điển dữ liệu & báo cáo chất lượng dữ liệu tự động

2. GIAI ĐOẠN 2: KHUNG ĐÁNH GIÁ VÀ THÍ NGHIỆM SELECTION BIAS (TUẦN 5-7)

Mục tiêu giai đoạn: Đảm bảo mọi con số hiệu năng mô hình của các thành viên đều trung thực, khách quan và chứng minh bằng thực nghiệm tác hại nghiêm trọng của hiện tượng thiên lệch chọn lọc (Selection Bias - Giả thuyết H3).

Các đầu việc chi tiết:

- **Xây dựng khung đánh giá dùng chung (src/evaluate.py):** Viết hàm evaluate(pipeline, X, y, scheme) hỗ trợ 4 sơ đồ kiểm thử chuẩn hóa: chia gốc original_split (38/34), loocv, nested_cv và wrong_cv.
- **Tính toán chỉ số & Kiểm định thống kê:** Lập trình tính toán đầy đủ các chỉ số hiệu năng (Balanced Accuracy, AUC, Sensitivity, Specificity), khoảng tin cậy Wilson 95% và thực hiện kiểm định McNemar để so sánh ý nghĩa thống kê giữa các cặp mô hình trên tập kiểm tra.
- **Thực hiện thí nghiệm Selection Bias (H3):** Thiết kế thí nghiệm hoán vị ngẫu nhiên 100 lần kết hợp chạy qua Cross-Validation đúng (chọn gen trong CV) và CV sai (chọn gen ngoài CV) nhằm phơi bày hiện tượng tăng hiệu năng giả tạo; trực quan hóa kết quả qua biểu đồ F10 (Violin/strip plot).
- **Đánh giá mô hình cuối cùng:** Vẽ đường cong ROC và ma trận nhầm lẫn (Confusion Matrix) cho mô hình phân loại tốt nhất được cả nhóm thống nhất lựa chọn (Hình F11).
- **Rà soát rò rỉ dữ liệu (Data Leakage Review):** Trực tiếp kiểm tra mã nguồn của các thành viên TV1, TV3, TV4 để đảm bảo các bước chọn biến, chuẩn hóa không bị rò rỉ thông tin từ tập kiểm tra độc lập.

Sản phẩm bàn giao Giai đoạn 2:

Hạng mục	Tên file / Sản phẩm	Mô tả / Vị trí
Khung đánh giá	src/evaluate.py	Module chứa hàm evaluate() và các phương pháp kiểm định thống kê
Notebook thí nghiệm	notebooks/08_evaluation.ipynb	Notebook thực hiện thí nghiệm Selection Bias và kiểm định McNemar
Trực quan hóa F10	reports/figures/F10_selection_bias.*	Biểu đồ Violin/strip plot so sánh CV đúng vs CV sai (H3)
Trực quan hóa F11	reports/figures/F11_final_model.*	Đường cong ROC và Ma trận nhầm lẫn của mô hình cuối cùng
Báo cáo chuyên môn	Báo cáo mục 3.5 & Bảng chỉ số	Bảng tổng hợp chỉ số hiệu năng và nội dung phân tích mục 3.5

3. BẢNG TỔNG HỢP TOÀN BỘ ĐẦU VIỆC CỦA TV2

Giai đoạn	Nhiệm vụ chính	Sản phẩm cụ thể	Mục đích & Ý nghĩa
Giai đoạn 1 (Tuần 1-4)	Nạp, hợp nhất & kiểm tra chất lượng dữ liệu	- src/load.py - src/quality.py - tests/test_load.py - data/standardized/* - docs/data_dictionary.md	Đảm bảo dữ liệu sạch, có cấu trúc chuẩn hóa, có thể truy xuất nguồn gốc cho toàn bộ nhóm phát triển mô hình.
Giai đoạn 2 (Tuần 5-7)	Khung đánh giá & Thí nghiệm Selection Bias	- src/evaluate.py 08_evaluation.ipynb - Biểu đồ F10, F11 - Nội dung Báo cáo 3.5	Đánh giá mô hình công bằng, chứng minh tác hại của Selection Bias (H3) và rà soát chống rò rỉ dữ liệu.